

ĐẠI HỌC BÁCH KHOA THÀNH PHỐ HỒ CHÍ MINH

KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÀI TẬP LỚN SỐ 2

**HỌC SÂU VÀ ỨNG DỤNG TRONG THỊ
GIÁC MÁY TÍNH**

Thành viên: Lê Đức Phương	2570480
Nguyễn Đình Khánh	2570227
Nguyễn Huy Hoàng	2570089
Nguyễn Huỳnh Như	2570471

NỘI DUNG BÀI THUYẾT TRÌNH

1 MỞ ĐẦU

2 SO SÁNH CÁC KIẾN TRÚC KHÁC NHAU

3 SO SÁNH CÁC BACKBONE KHÁC NHAU

4 SO SÁNH SEMANTIC VS INSTANCE

PHẦN

1

MỞ ĐẦU

1. MỞ ĐẦU

1.1 Giới thiệu đề tài

- Phân đoạn ảnh là bài toán cốt lõi trong thị giác máy tính, được ứng dụng rộng rãi trong xe tự hành, y tế và phân tích cảnh quan.
- Sự đa dạng kiến trúc hiện nay đặt ra câu hỏi thực tiễn về việc lựa chọn mô hình phù hợp cho từng bài toán cụ thể.
- Báo cáo này thực hiện ba hướng so sánh có hệ thống trên tập dữ liệu Pascal VOC 2012.

Hướng So Sánh	Mô Hình	Điều Kiện Kiểm Soát
(1) So sánh kiến trúc	U-Net vs DeepLabV3	Cố định backbone ResNet-50
(2) So sánh backbone	ResNet-50 vs ConvNeXt-Tiny vs Swin-Tiny	Cố định kiến trúc DeepLabV3
(3) So sánh paradigm	Semantic (DeepLabV3 ResNet-50) vs Instance (Mask R-CNN ResNet-50-FPN)	Cố định Base Backbone (ResNet-50)

1. MỞ ĐẦU

1.2 Mô tả tập dữ liệu



- Benchmark tiêu chuẩn được cộng đồng nghiên cứu quốc tế công nhận rộng rãi.
- 20 lớp thuộc 4 nhóm ngữ nghĩa đa dạng, có đồng thời semantic mask và instance mask
- Quy mô vừa phải, khả thi huấn luyện

Pascal VOC 2012

Số lớp	20 lớp đối tượng + background
---------------	-------------------------------

Tập train	10,582 ảnh
------------------	------------

Tập validation	1,449 ảnh
-----------------------	-----------

Mask Semantic	SegmentationClass
----------------------	-------------------

Mask Instance	SegmentationObject
----------------------	--------------------

PHẦN


2

SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.1 U-Net


- Kiến trúc đối xứng dạng Encoder - Decoder, được thiết kế ban đầu chuyên dụng cho phân vùng ảnh y tế
- Mạnh ở phục hồi biên cạnh nhờ thiết kế Skip-Connection chữ U, Skip-connection giúp ghép nối chi tiết từ các lớp nông sang lớp sâu.
- Nhược điểm: Thiếu cái nhìn toàn cục toàn ảnh. Không linh hoạt với kích thước ảnh, thường yêu cầu resize hoặc crop ảnh đầu vào phức tạp.



2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.2 DeepLabV3

- Sử dụng các Backbone mạnh mẽ như ResNet hoặc MobileNet để trích xuất đặc trưng.
- Sử dụng cốt lõi ASPP (Atrous Spatial Pyramid Pooling) áp dụng linh kiện tích chập giãn nở đa tỉ lệ.
- Ưu điểm: Phá vỡ rào cản tỷ lệ đối tượng, hiểu được bối cảnh vĩ mô lẫn vi mô.
- Mở rộng trường nhìn (Receptive field) hiệu quả: Tích chập giãn nở (Dilated/Atrous Convolution) giúp nhìn được vùng ảnh rộng hơn mà không làm tăng số lượng tham số hay mất đi độ phân giải.






2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.3 Thiết lập Thực nghiệm (Experimental Setup)

- **Dataset:** PASCAL VOC 2012 (21 nhãn lớp).
- **Backbone chung:** ResNet-50.
- Tham số Huấn luyện:
 - **Optimizer:** AdamW | **Hàm Loss:** CrossEntropy.
 - **Epochs:** 50 | **Batch Size:** 64 | **Độ phân giải:** Cắt mảng (Crop) kích thước vuông 512x512.
- Cơ chế phụ trợ:
 - Sử dụng Early Stopping (Patience = 10 epoch).
 - Tích hợp Tensorboard theo dõi dòng thời gian Loss và Tự động đánh giá Checkpoint tốt nhất.

2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.4 Kết quả Thực nghiệm & Đối chiếu Kiến trúc



2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.4 Kết quả Thực nghiệm & Đối chiếu Kiến trúc

- Kiến trúc DeepLabV3+ mang lại kết quả cực kỳ ấn tượng, đánh bại hoàn toàn U-Net với khoảng cách mIoU lên tới 15.78%
- Thực tiễn chứng minh mô đun ASPP của họ nhà DeepLab cực kỳ phù hợp với các tập dữ liệu ảnh chụp cảnh thực tế phức tạp (chứa sinh vật, đồ vật, nền cảnh đa dạng) như PASCAL VOC.

Mô hình	Backbone	mIoU	Dice Score
U-Net	ResNet-50	0.4769	0.5854
DeepLabV3+	ResNet-50	0.6347	0.7350

2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3


2.5 Tăng cường Dữ liệu với Copy-Paste Augmentation

- Phương pháp tách biệt ngẫu nhiên đối tượng từ ảnh nguồn dựa trên mặt nạ nhãn, dán vô hướng đề lên không gian ảnh mục tiêu trong lúc khởi chạy vòng lặp huấn luyện.

Target Ảnh Gốc



Target Mask Gốc (Đáp án)



Ảnh được dán thêm Vật thể (Copy-Paste)






Mask chứa vật thể được dán



2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.5 Tăng cường Dữ liệu với Copy-Paste Augmentation


- So với mô hình gốc, các thang chỉ số có phần giảm nhẹ rớt nhíp.
- Phân tích nguyên nhân: Kỹ thuật này sinh ra vùng nhiều nhân tạo bất logic mạnh mẽ (Extreme Regularization). Ở quy mô hẹp 50 Epochs, hệ thống bị cản trở hội tụ nhanh do phải xử lý các hình phạt vô lý, bù lại mô hình lại học được cách tự vệ chống overfitting vững chắc hơn trên thực tế.



2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.6 Giải thích Mô hình bằng XAI: Phân tích Ca kiểm thử Grad-CAM

- **U-Net:** Dự đoán dính lỗi nhiều (nhận nhầm cừu thành cái chai / nhãn khác - bệt nâu).
- **DeepLabV3+ Baseline:** Nhận diện hoàn hảo cấu trúc khối, bao quát ngữ cảnh xuất sắc, không hề bị rách mảnh.
- **DeepLabV3+ (Copy-Paste):** Tái diễn lỗi rải đốm màu do tàn dư của quá trình sinh dữ liệu khó (Regularization).



2. SO SÁNH KIẾN TRÚC U-Net vs DeepLabV3

2.7 Demo App

Cross-architecture checkpoints

UNet ResNet-50 checkpoint

artifacts/experiments/unet_resnet5

DeepLabV3+ ResNet-50 checkpoint

artifacts/experiments/deeplabv3pl

DeepLabV3+ ResNet-50 (CopyPaste) checkpoint

artifacts/experiments/deeplabv3pl

Image

Pick a sample image

inputs/2007_003525.jpg

or Upload image

Upload

200MB per file • JPG, JPEG, PNG

Input preview width (px)

320

Output image width (px)

240

Run cross-architecture comparison

UNet ResNet-50



Overlay



Predicted mask

DeepLabV3+ ResNet-50



Overlay



Predicted mask

DeepLabV3+ ResNet-50 (CopyPaste)



Overlay



Predicted mask

PHẦN

3

SO SÁNH CÁC BACKBONE KHÁC NHAU

Trình bày cơ sở lý thuyết, đặc trưng kiến trúc và so sánh hiệu quả thực nghiệm giữa các backbone được sử dụng trong mô hình phân đoạn ảnh.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.1 Câu hỏi nguyên cứu và nguyên tắc so sánh

Câu hỏi trung tâm

Nếu giữ decoder, optimizer và pipeline đánh giá không đổi, backbone nào tạo ra biểu diễn tốt hơn để cải thiện chất lượng pixel-level mask?

Ba backbone trong project

- ✗ ResNet-50: CNN residual cổ điển
- ✗ ConvNeXt-Tiny: CNN hiện đại hoá
- ✗ Swin-Tiny: hierarchical Transformer

Vì sao chỉ so backbone?

- ✗ Segmentation head được giữ là DeepLabV3+ cho cả ba chạy.
- ✗ Dataset, split và metric đều giống nhau nên chênh lệch chủ yếu đến từ feature extractor.
- ✗ Nhờ vậy, phần kết quả có giá trị học thuật hơn việc thay nhiều thành phần cùng lúc.

Ý nghĩa của slide này


Backbone không phải phần “phụ” của semantic segmentation. Chính nó quyết định feature trước ASPP/decoder đủ giàu để giữ biên, gom ngữ cảnh và phân tách lớp hay không.

Nói ngắn gọn: đổi backbone là đổi chất lượng representation, và đó là lý do kết quả giữa ba mô hình có thể khác nhau dù head giống nhau.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.1 DeepLabV3+ giữ cố định để backbone công bằng

DeepLabV3+ giữ cố định, chỉ đổi backbone



Encoder thay đổi -> feature map thay đổi -> chất lượng segmentation thay đổi.

Lý do phải cố định DeepLabV3+

- ❌ ASPP gom ngữ cảnh đa tỉ lệ như nhau ở cả ba chạy.
- ❌ Decoder đều dùng low-level features nên sự khác biệt đến từ encoder.
- ❌ Kết quả vì thế dễ diễn giải hơn trong báo cáo.

Thiết lập trong artifacts

- ❌ Dataset: Pascal VOC 2012
- ❌ Metrics: mIoU, Dice, Pixel Accuracy
- ❌ 40 epochs / run


Điều nên nói khi thuyết trình

Phần này không so “mô hình end-to-end” nào tốt hơn, mà so encoder nào tạo ra feature map hữu ích hơn khi cắm vào cùng một DeepLabV3+ pipeline.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.2 Model 1 - ResNet50

Residual feature hierarchy



Shortcut giúp gradient ổn định và giữ locality rất tốt.

Điểm cốt lõi

- ✗ Residual shortcut giúp mạng sâu ổn định hơn.
- ✗ CNN hierarchy vốn mạnh ở edges, textures và locality.
- ✗ Vì thế ResNet-50 là baseline rất hợp lý cho segmentation.

Kỳ vọng với semantic segmentation

- ✗ Biên và cấu trúc nhỏ thường khá ổn.
- ✗ Hạn chế nằm ở context modeling dài hạn.
- ✗ Ceiling mIoU dễ thấp hơn các encoder mới hơn.


Cách nói ngắn gọn

ResNet-50 là mốc so sánh công bằng: đủ mạnh để nghiêm túc, đủ quen thuộc để dễ giải thích, nhưng vẫn dễ lộ rõ lợi ích nếu backbone mới thật sự tốt hơn.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.3 Model 2 - ConvNext-Tiny

Modernized CNN block



ConvNeXt vẫn là CNN, nhưng block được hiện đại hoá để tăng semantics.

Điểm khác với ResNet-50

- ❌ Semantics tầng cao thường giàu hơn.
- ❌ Vẫn giữ CNN inductive bias cho locality.
- ❌ Trade-off giữa độ mạnh và độ đơn giản rất đẹp.

Kỳ vọng trong artifacts

- ❌ Mask gọn hơn, vùng đối tượng “đầy” hơn.
- ❌ Validation metric thường nhảy rõ hơn so với baseline cổ điển.

ConvNeXt-Tiny là gì?

Đây vẫn là CNN thuần, nhưng block được “thiết kế lại” theo tư duy benchmark hiện đại: kernel lớn hơn, LayerNorm/GELU và stage design gọn hơn để tăng representational power.


Cách nói ngắn gọn

ConvNeXt-Tiny là câu trả lời cho ý tưởng “CNN hiện đại hoá”: không bỏ convolutional prior, nhưng đủ mạnh để tiến rất gần Transformer trong dense prediction.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.4 Model 3 - SwinTiny

Shifted-window attention



Local window giữ chi phí thấp, shift window giúp trao đổi context giữa các vùng.

Điểm mạnh lý thuyết

- ✗ Context aggregation mạnh nhất trong ba encoder.
- ✗ Hierarchical design phù hợp với segmentation.
- ✗ Thường có ceiling cao nhất ở scene khó.

Kỳ vọng trên Pascal VOC

- ✗ Tốt hơn khi cảnh có context rộng hoặc local patch dễ mở hồ.
- ✗ Biên vẫn có thể tốt nếu decoder tận dụng pyramid feature hợp lý.

Điểm mấu chốt của Swin-Tiny

Swin dùng attention theo local windows rồi dịch chuyển cửa sổ giữa các block. Nhờ vậy, nó mở rộng context tốt hơn CNN thuần mà chi phí vẫn được kiểm soát.

Cách nói ngắn gọn

Swin-Tiny là lựa chọn ưu tiên context: nó thường không “thắng áp đảo”, nhưng là ứng viên có ceiling tốt nhất khi mục tiêu là đẩy trần chất lượng segmentation.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.5 Tóm tắt bản chất của từng mô hình

Tiêu chí	ResNet-50	ConvNeXt-Tiny	Swin-Tiny
Building block	Residual bottleneck CNN	Modernized convolution block	Shifted-window Transformer
Inductive bias	Mạnh về locality, translation invariance	Vẫn là CNN prior nhưng semantics giàu hơn	Ít bias thủ công hơn, context mạnh hơn
Điểm mạnh	Ổn định, boundary-friendly baseline	Trade-off rất mạnh giữa locality và richness	Context modeling tốt nhất
Điểm yếu	Ceiling thấp hơn về ngữ cảnh dài hạn	Không phải lúc nào cũng vượt xa Transformer	Kiến trúc phức tạp hơn
Kỳ vọng segmentation	Baseline tốt, dễ tái lập	Phương án cân bằng nhất	Ceiling accuracy cao nhất

Cách đọc bảng

- ✗ ResNet-50 = baseline ổn định và locality mạnh.
- ✗ ConvNeXt-Tiny = CNN hiện đại hoá, thường là trade-off đẹp nhất.
- ✗ Swin-Tiny = context mạnh nhất và có ceiling accuracy cao nhất.


3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.6 Kết quả định lượng sau khi training model

Backbone	Best mIoU	Best Dice	Best Pixel Acc.	Best epoch
ResNet-50	0.7175	0.8247	0.9304	37
ConvNeXt-Tiny	0.7422	0.8425	0.9406	31
Swin-Tiny	0.7447	0.8443	0.9411	33

Điểm đọc nhanh



- ❌ Swin-Tiny đứng đầu ở cả ba metric.
- ❌ ConvNeXt-Tiny bám rất sát, chênh mIoU chỉ ~0.0025.
- ❌ ResNet-50 thấp hơn nhưng vẫn là baseline rất cạnh tranh.
- ❌ Best epoch của ba backbone rơi vào khoảng 31–37.



Thứ hạng nhất quán trong run thực tế: Swin-Tiny > ConvNeXt-Tiny > ResNet-50.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.7 Kết quả sau khi training theo từng epoch



Độc đường mIoU


Swin-Tiny khởi đầu mạnh nhất; ConvNeXt-Tiny tăng dần và bám sát ở nửa sau; ResNet-50 cải thiện đều nhưng ceiling thấp hơn.

Độc đường val loss

ResNet-50 có val loss thấp hơn ở cuối nhưng mIoU vẫn thua top-2. Điều này nhắc rằng loss và segmentation quality không luôn xếp hạng giống nhau.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.8 Ví dụ thực tế của một tập ảnh sau khi training mô hình



Train scene

ResNet-50 để lộ “lỗ” rõ hơn trong vùng train; ConvNeXt và Swin lấp kín vùng đối tượng tốt hơn.

Two people


Cả ba mô hình đều bắt được silhouette chính; khác biệt nằm ở biên vai, tóc và vùng đen nhỏ giữa hai người.

Cách đọc hình

Đây là prediction export gốc của pipeline: nửa trái là input, nửa phải là mask dự đoán.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.9 Ví dụ thực tế và kết luận chọn backbone



Airplane

Đây là ví dụ dễ: cả ba backbone đều cho mask máy bay khá kín. Vì thế metric tổng hợp mới quan trọng.

Cyclists

Ở cấu trúc mảnh như bánh xe và khoảng rỗng nội tại, ConvNeXt / Swin thường gọn hơn đôi chút so với ResNet.

Chốt lựa chọn mô hình

ResNet-50 = baseline tốt;
ConvNeXt-Tiny = trade-off đẹp nhất;
Swin-Tiny = chất lượng tốt nhất nếu ưu tiên trần mIoU.

3. SO SÁNH CÁC BACKBONE KHÁC NHAU

3.10 Demo App

ConvNeXt-Tiny checkpoint
artifacts/experiments/deeplabv3pl

Swin-Tiny checkpoint
artifacts/experiments/deeplabv3pl

Image

Pick a sample image
inputs/2007_003525.jpg

or Upload image

Drag and drop file here
Limit 200MB per file • JPG, JPEG, PNG


Browse files

Input preview width (px)
320

Output image width (px)
240

Run inference

Input preview

ResNet-50	ConvNeXt-Tiny	Swin-Tiny
		
Overlay	Overlay	Overlay
		
Predicted mask	Predicted mask	Predicted mask

PHẦN

4

SO SÁNH SEMANTIC VS INSTANCE

Trình bày cài đặt thực nghiệm, kết quả huấn luyện

định lượng, phân tích định tính và thảo luận so


sánh toàn diện giữa hai phương pháp phân đoạn

ảnh Semantic vs Instance

4. SO SÁNH SEMANTIC VS INSTANCE

4.1 Kiến trúc mô hình

Kiến trúc DeepLabV3 + ResNet-50 (Semantic Segmentation)




Các thành phần chính:

- **ResNet-50 Backbone:** Mạng tích chập sâu với các residual connections, được pre-train trên ImageNet/COCO và fine-tune trên Pascal VOC. Output stride = 16.
- **ASPP (Atrous Spatial Pyramid Pooling):** Module trung tâm của DeepLabV3. Sử dụng song song các dilated convolution với tốc độ khác nhau ($r = 6, 12, 18$) cùng global average pooling để mô hình hóa ngữ cảnh ở nhiều tỷ lệ khác nhau mà không làm giảm độ phân giải.
- **Classifier Head:** Lớp tích chập 1×1 chuyển đổi feature map 256 chiều thành 22 kênh đầu ra.

4. SO SÁNH SEMANTIC VS INSTANCE

4.1 Kiến trúc mô hình

Kiến trúc Mask R-CNN + ResNet-50-FPN (Instance Segmentation)



Các thành phần chính:

- **FPN (Feature Pyramid Network):** Kết hợp với ResNet-50 để tạo feature maps đa tỷ lệ (P2–P6), cho phép phát hiện đối tượng nhỏ và lớn đồng thời.
- **RPN:** Sliding-window classifier + regressor để sinh region proposals với anchor boxes đa tỷ lệ và tỷ lệ khung hình.
- **RoI Align:** Bilinear interpolation để trích xuất đặc trưng chính xác không bị lỗi quantization.
- **Ba nhánh song song:** Box regression, classification (2 lớp: BG/FG), mask prediction (28×28 binary mask).

4. SO SÁNH SEMANTIC VS INSTANCE

4.2 Quy trình huấn luyện

Thông số	DeepLabV3 + ResNet-50	Mask R-CNN + ResNet-50-FPN
Optimizer	Adam	SGD
Learning rate	1e-4	0.005
Momentum	—	0.9
Weight decay	—	5e-4
Batch size	8	4
Epochs	20	20
Pre-trained weights	COCO	COCO
Thời gian train/epoch	~2 phút 20 giây	~9 phút 25 giây
Số tham số	~39.6M	~43.9M (trainable: 43.7M)

Transfer learning: Cả hai mô hình khởi tạo từ weights pre-trained trên COCO, thay thế lớp đầu ra để phù hợp Pascal VOC. Chiến lược này giúp mô hình kế thừa đặc trưng đã học, giảm nguy cơ overfitting và rút ngắn thời gian hội tụ.

4. SO SÁNH SEMANTIC VS INSTANCE

4.2 Quy trình huấn luyện

TIỀN XỬ LÝ — DEEPLABV3 (SEMANTIC)


Resize	256×256 (BILINEAR cho ảnh, NEAREST cho mask)
ToTensor	Chuẩn hóa $[0,255] \rightarrow [0,1]$
Normalize	mean=[0.485,0.456,0.406], std=[0.229,0.224,0.225]
DataLoader	batch_size=8, shuffle=True, num_workers=2

TIỀN XỬ LÝ — MASK R-CNN (INSTANCE)

Instance mask	Trích xuất N binary masks từ SegmentationObject
Bounding box	Tính [xmin, ymin, xmax, ymax] từ từng binary mask
Target format	boxes, labels=1, masks, area, iscrowd=0
DataLoader	batch_size=4, custom collate_fn (N instance khác nhau)

4. SO SÁNH SEMANTIC VS INSTANCE

4.3 Kết quả huấn luyện - Semantic




Training Loss: giảm từ 1.5541 $\rightarrow$ 0.0465 (giảm 83.6% trong 5 epoch đầu, sau đó chậm dần). Phản ánh hiệu quả transfer learning từ COCO: mô hình nhanh chóng thích nghi.

Overfitting từ Epoch 6: Val mIoU dao động [0.39, 0.44] trong 15 epoch cuối trong khi Train Loss tiếp tục giảm. Biên độ dao động $\sim \pm 0.05$ là biểu hiện rõ ràng của overfitting. Nguyên nhân: thiếu augmentation hình học, LR cố định, không early stopping.

Kết luận: Epoch 5 là điểm tối ưu (mIoU = 0.4515, Train Loss = 0.2541)

4. SO SÁNH SEMANTIC VS INSTANCE

4.3 Kết quả huấn luyện - Instance



mAP@0.5 (~0.75–0.80): Metric dễ nhất ($\text{IoU} \geq 0.5$). Transfer learning từ COCO cung cấp khả năng phát hiện và định vị thô rất tốt ngay từ epoch đầu (0.750).

mAP@[0.5:0.95] (~0.46–0.51): Metric tổng hợp COCO-style. Khoảng cách lớn với mAP@0.5 cho thấy localization chính xác (IoU cao) vẫn còn hạn chế.

Overfitting sau Epoch 9: Xu hướng giảm dần của mAP@0.5 (xuống ~0.745) và dao động mAP@[.5:.95] phản ánh overfitting

4. SO SÁNH SEMANTIC VS INSTANCE

4.4 Các kết quả định lượng


Chỉ số hiệu suất	DeepLabV3 + ResNet-50	Mask R-CNN + ResNet-50-FPN
Metric chính (val)	mIoU = 0.4515	mAP@[0.5:0.95] = 0.5060
Metric phụ	—	mAP@0.5 = 0.7748 mAP@0.75 = 0.5536
Epoch tối ưu	Epoch 5 / 20	Epoch 9 / 20
Số tham số	~39.6M	~43.9M (trainable: 43.7M)
FPS (inference, CPU)	~24 FPS	~7 FPS
Latency mỗi ảnh	~42 ms	~142 ms
Thời gian train/epoch	~3 phút	~13 phút
Tổng thời gian (GPU)	~1 giờ	~4.5 giờ

mIoU và mAP là hai metric đo lường các khía cạnh hoàn toàn khác nhau — không thể so sánh trực tiếp về giá trị số. mIoU đánh giá chồng lấp pixel toàn cảnh (semantic); mAP đánh giá khả năng phát hiện và localize từng instance. DeepLabV3 nhanh hơn ~3.4× khi inference và ~4.3× khi training, nhưng đây phản ánh sự khác biệt về độ phức tạp bài toán, không phải chất lượng mô hình.

4. SO SÁNH SEMANTIC VS INSTANCE

4.5 Các kết quả định tính

A: Nhiều instance cùng lớp (~15 người + 2 xe máy)



Semantic Toàn bộ "person" tô cùng màu — không phân biệt 15 cá thể.

Instance Mỗi cá thể mask riêng, confidence >0.90.

-> Ưu thế vượt trội của Instance Segmentation trong đám đông. Trong các ứng dụng giám sát, đếm người hay navigation tự động, Instance Segmentation là lựa chọn phù hợp hơn.

4. SO SÁNH SEMANTIC VS INSTANCE

4.5 Các kết quả định tính

B: Nhiều lớp đối tượng (chair + table+ tree)



Semantic phân biệt rõ ràng ba lớp bằng ba màu VOC chuẩn riêng biệt, dù Ground Truth còn có thêm lớp bottle mà mô hình chưa nhận ra.

Instance Mô hình phát hiện được 8 instances khớp với 8 objects trong Ground Truth, với bounding box và mask chính xác cho từng cá thể riêng biệt. Tuy nhiên, tất cả đều chỉ được gán nhãn “foreground” — không biết đây là ghế hay bàn, tức là mất đi thông tin ngữ nghĩa về loại đối tượng.

-> Semantic Segmentation chiếm ưu thế vượt trội trong nhận dạng ngữ nghĩa đa lớp.


Ngược lại, Instance Segmentation chỉ ra các cá thể riêng biệt nhưng không bày được “đây là loại gì”

-> **Đánh đổi cơ bản giữa hai paradigm: ngữ nghĩa vs. phân tách cá thể.**

4. SO SÁNH SEMANTIC VS INSTANCE

4.5 Các kết quả định tính

C: Một lớp, nhiều đối tượng (5 người)



Semantic 5 người được tô chung màu "person". Mô hình trả lời được "có người trong ảnh" nhưng không định lượng được số lượng

Instance 5 người được phát hiện và phân đoạn riêng biệt với confidence score rất cao (0.90–0.99), màu sắc phân biệt rõ ràng cho từng cá thể. Mô hình trả lời chính xác "có 5 người trong ảnh".

-> Cả hai đều nhận dạng được sự hiện diện, nhưng chỉ Instance Segmentation có khả năng định lượng và phân tách cá thể chính xác.

4. SO SÁNH SEMANTIC VS INSTANCE

4.5 Các kết quả định tính

Semantic Segmentation (DeepLabV3): Hiểu ngữ nghĩa toàn cảnh tốt, gán nhãn toàn bộ pixel nhất quán. Không thể phân biệt các instance riêng lẻ cùng lớp — hạn chế trong đám đông và vật thể chồng lấp.

Instance Segmentation (Mask R-CNN): Phân biệt từng đối tượng riêng lẻ, đếm chính xác, xuất sắc với nhiều instance.

Hạn chế: không phân loại ngữ nghĩa đầy đủ do cấu hình 2-class.

4. SO SÁNH SEMANTIC VS INSTANCE

4.6 Thảo Luận — Ưu và Nhược Điểm

DeepLabV3 (Semantic Segmentation)

Ưu điểm	Nhược điểm
• Phân loại ngữ nghĩa đầy đủ (21 lớp VOC) • Tốc độ cao (~24 FPS, phù hợp real-time) • Kiến trúc nhẹ hơn (~39.6M params) • Huấn luyện nhanh (~3 phút/epoch) • Pipeline đơn giản, dễ triển khai	• Không phân biệt các instance cùng lớp • Không cung cấp bounding box • Không thể đếm số lượng đối tượng

4. SO SÁNH SEMANTIC VS INSTANCE

4.6 Thảo Luận — Ưu và Nhược Điểm

Mask R-CNN (Instance Segmentation)

Ưu điểm	Nhược điểm
• Phân biệt từng cá thể riêng lẻ • Bounding box + confidence score đầy đủ • Đếm chính xác số lượng đối tượng • Phù hợp tracking, counting, robotics • Multi-task learning phong phú	• Tốc độ thấp (~7 FPS) • Kiến trúc nặng hơn (~43.9M params) • Không phân loại ngữ nghĩa (cấu hình 2-class) • Pipeline phức tạp hơn, khó triển khai

4. SO SÁNH SEMANTIC VS INSTANCE


4.7 Demo App

Semantic vs Instance Segmentation


DeepLabV3 (pixel-level class map) · Mask R-CNN (per-object mask)



Input



Semantic (DeepLabV3)



Instance (Mask R-CNN)

Controls

Image source

☒ Sample images ☐ Upload

Pick a sample

2007_001311.jpg

Instance confidence threshold

0.50

Run

Metrics

Semantic latency	Instance latency	Detected classes	Detected instances
164 ms	1078 ms	3	10

Semantic — detected classes

- bicycle

Instance — 10 object(s) detected (threshold 0.5)

#	Class	Confidence	Box (x1,y1,x2,y2)	Mask area (px)
1	person	1.00		
2	person	1.00		
3	bicycle	0.99		
4	person	1.00		
5	bicycle	1.00		
6	motorbike	0.89		
7	person	1.00		
8	person	0.99		
9	person	0.99		
10	person	0.99		

4. SO SÁNH SEMANTIC VS INSTANCE

4.6 Thảo Luận — Ưu và Nhược Điểm

Semantic Segmentation phù hợp khi: Cần phân loại ngữ nghĩa toàn cảnh, yêu cầu real-time (~24 FPS), tài nguyên tính toán hạn chế. Ứng dụng: xe tự hành, phân tích cảnh, ảnh y tế.

Instance segmentation phù hợp khi: Cần đếm đối tượng, tracking từng cá thể, thao tác vật lý với đối tượng riêng lẻ. Ứng dụng: giám sát đám đông, robot gấp vật, phân tích tế bào.

Kết luận chính: Hai phương pháp phục vụ hai nhu cầu khác nhau. Không có phương pháp nào vượt trội tuyệt đối — lựa chọn phụ thuộc vào yêu cầu ứng dụng cụ thể.

Tài Liệu Tham Khảo

- [1] **Chen, L.-C., Papandreou, G., Schroff, F., & Adam, H.** (2017). Rethinking Atrous Convolution for Semantic Image Segmentation. *arXiv preprint arXiv:1706.05587*.
-
- [2] **He, K., Gkioxari, G., Dollár, P., & Girshick, R.** (2017). Mask R-CNN. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2961–2969.
-
- [3] **Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A.** (2010). The Pascal Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision*, 88(2), 303–338.
- [4] **He, K., Zhang, X., Ren, S., & Sun, J.** (2016). Deep Residual Learning for Image Recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778.
-

**THANK
YOU**